

Peta Jalan: Aplikasi Diagnosis Matematika Anak

Satu dokumen yang menggabungkan arah produk, taksonomi B/K/H, hasil riset dua-putaran, rencana spike, dan roadmap setelahnya — supaya tidak perlu buka lima percakapan berbeda untuk tahu di mana kita berdiri.

- Status sekarang: **siap eksekusi Fase 0 — spike 5–7 hari**, belum ada satu baris kode pun ditulis.

01 Arah produk

Keputusan yang sudah disepakati 14 Agustus 2026, jadi dasar semua yang lain di dokumen ini.

LINGKUP V1	Satu keluarga saja (anak sendiri), tanpa akun, tanpa multi-tenant.
TARGET ANAK	Kelas 4, TA 2026/2027. PDF sumber ditulis untuk kelas 5 menuju OSN 2027 — tidak langsung berlaku. Target OSN realistis 2028, perlu lapisan pra-fondasi yang belum ada di PDF manapun.
BUKAN KALENDER	Peta 20 minggu didekompilasi jadi graf topik berprasyarat. Penggeraknya kondisi anak, bukan tanggal — bolong seminggu tidak menimbulkan "utang sesi".
OSN = KESIMPULAN	Bukan mode yang dipilih saat daftar. Tiap soal punya tingkat: 1 2 3 . Kata "OSN" tidak boleh hardcode di kode atau struktur data.
AI DI BELAKANG	Tidak pernah jadi tutor chat untuk anak. AI duduk di belakang orang tua, bukan di depan anak.
INPUT ANAK	Tulisan tangan berlangkah di kanvas HP. Jawaban akhir diketik, bukan hasil OCR — OCR tidak pernah menentukan benar/salah.
RITME	Realistis 3 sesi/minggu, 30–40 menit — bukan 4 hari + Jumat + Sabtu seperti di modul sumber.

Kenapa ini penting: orang tua di Indonesia kebanyakan tidak mengejar OSN — cukup nilai matematika membaik. Nilai jual sebenarnya bukan OSN, melainkan diagnosis: rapor bilang "Matematika 78", aplikasi ini bilang penyebabnya topik apa saja.

02 Taksonomi B/K/H

Inti mesin diagnosis — aset paling bernilai dari PDF *Tes Kalibrasi - Panduan Orang Tua*, bukan soal-soalnya.

- **B** — salah baca soal. **K** — salah konsep. **H** — salah hitung.
- Metrik utama aplikasi = jumlah **K aktif per topik** dan trennya, **bukan skor**. "Anak dengan sembilan H dan skor 11 sebenarnya jauh lebih siap daripada anak dengan tiga K dan skor 15."
- **Tabel sidik jari jawaban salah:** jawaban tertentu memetakan ke diagnosis spesifik.
Contoh: $2/3 + 3/4 - 1/2$ dijawab $4/5$ → pembilang & penyebut dijumlahkan sendiri-sendiri, konsep pecahan belum terbentuk.
- **Uji Ulang Lisan** (PDF terpisah) memisahkan "tidak bisa" dari "tidak dikerjakan".

Tinta digital bertimestamp bisa memetakan otomatis ke B/K/H: lancar-tanpa-ragu-tapi-salah → K; langkah benar dengan koreksi di titik aritmetika → H; jawaban ditulis duluan lalu langkah menyusul → menebak.

03 Ringkasan riset

Dua putaran riset multi-sumber (10 sudut, 47 sumber, 38 klaim lolos verifikasi adversarial 3-vote). Laporan lengkap dengan sitasi ada di [osn-riset-bkh.html](#) — bagian ini ringkasannya, klik tiap baris untuk detail.

Knowledge tracing memvalidasi "jangan pakai skor"

BKT/DKT secara struktural cuma bisa mengestimasi mastery agregat, bukan mendiagnosis akar kesalahan — keterbatasan bentuk data (benar/salah biner), bukan soal implementasi. **Option tracing** dan **Graph-based Knowledge Tracing** jadi presedan akademik untuk pendekatan tagging-K dan graf topik berprasyarat.

Peringatan: MalruleLib menunjukkan AI kesulitan generalisasi satu contoh kesalahan anak ke soal baru berbeda template (akurasi 66%→40%) — jangan andalkan AI menebak miskonsepsi baru secara bebas.

[arxiv.org/2104.09043](#) · [arxiv.org/2105.15106](#) · [arxiv.org/2601.03217](#)

Newman's Error Analysis — saudara akademik B/K/H

Kerangka 1977, masih dikutip 2019–2025. 5 tahap: Reading, Comprehension, Transformation, Process Skills, **Encoding**. $B \approx \text{Reading} + \text{Comprehension}$, $K \approx \text{Transformation}$, $H \approx \text{Process Skills}$. Kategori kelima (Encoding — paham & hitung benar tapi salah tulis jawaban akhir) tidak ada di B/K/H.

Historis dioperasikan lewat **protokol wawancara 5-prompt tetap**, bukan interpretasi bebas — bahkan dipasang sebagai poster kelas di NSW.

[mav.vic.edu.au](#) (White 2009) · [researchgate.net](#) · [files.eric.ed.gov](#)

OCR/HME untuk coretan fisik — risiko terdokumentasi

Model SOTA (VEHME, EMNLP 2025) gagal 11–70% pada kanvas berstruktur. VLM punya kebiasaan berbahaya "**memperbaiki**" **kesalahan anak** alih-alih mentranskrip apa adanya. Confidence measure grading cuma ~73% andal (false-positive rate 0,27).

Rekomendasi: SOP ambang ganda (auto-terima/auto-tolak/rute-ke-orang tua), selalu tampilkan transkripsi verbatim ke orang tua, kanvas bebas + OCR halaman-penuh lebih baik dari kotak jawaban kaku.

arxiv.org/2510.22798 · arxiv.org/2404.10690 · arxiv.org/2408.11728 · arxiv.org/2604.22774

PP 17/2025 — berlaku meski satu keluarga

"Penyelenggara Sistem Elektronik" eksplisit mencakup perorangan, bukan cuma institusi. Wajib persetujuan orang tua, wajib DPIA (bisa catatan ringkas), wajib hapus data kalau consent ditarik.

Arsitektur "tanpa izin INTERNET, diagnosis di Mac" yang sudah dipilih di rencana spike justru sejalan dengan arah minimalisasi data ini — belum ada preseden penegakan untuk operator individu skala kecil.

peraturan.go.id/pp-no-17-tahun-2025 · peraturan.bpk.go.id

Dashboard orang tua — celah riset, bukan kesimpulan

Hampir semua klaim spesifik tentang pola anti-data-overload untuk orang tua awam gagal verifikasi di kedua putaran. Satu-satunya yang lolos (IXL Trouble Spots) adalah produk institusional untuk guru, bukan orang tua individu.

Jangan bangun dashboard berdasarkan pola dari produk institusional — kalau dikerjakan, perlu riset+piloting terpisah.

blog.ixl.com

Klaim yang gagal verifikasi — jangan diasumsikan benar

Dynamic BKT sudah mengencode graf prasyarat secara otomatis — **ditolak**. DKT bisa menemukan struktur konsep laten tanpa tagging manusia — **ditolak**.

Ambang ganda terbukti mencapai $F1 > 0,985$ dengan $< 3\%$ masuk review — **ditolak** (pola metodologinya valid, angka performanya dari domain lain).

04 Rencana spike (5–7 hari)

Detail teknis lengkap sudah ditulis di [Rencana Spike – Coretan ke Diagnosis.html](#).

Bagian ini ringkasan yang bisa dicentang, plus tiga penyesuaian yang direkomendasikan riset sebelum eksekusi.

Asumsi yang dipertaruhkan

Apakah tinta bertimestamp + jawaban yang diketik cukup untuk mendiagnosis kesalahan anak sebagai B, K, atau H. Kalau tidak terbukti, produk ini turun jadi aplikasi latihan soal biasa.

Keputusan arsitektur inti

Aplikasi Android hanya merekam goresan → ekspor JSON. Diagnosis dijalankan terpisah oleh skrip Python di Mac (`claude-opus-5`). **Tidak ada izin**

`android.permission.INTERNET` sama sekali — tidak ada API key di APK, iterasi prompt dalam hitungan detik tanpa build ulang, risiko gagal terisolasi ke skrip saja.

Lulus **LANJUT BANGUN V1**

- Minimal 7 dari 10 kode B/K/H cocok dengan penilaian Bapak (setelah wawancara jadi penengah)
- Nol kasus AI menyebut "K" untuk kesalahan yang sebenarnya "H"
- Anak mau menulis di layar sampai soal ke-10 tanpa mengeluh soal alat tulisnya

Gagal **HENTIKAN, GANTI PENDEKATAN**

- Anak menolak menulis dengan jari, atau tulisannya jauh lebih buruk daripada di kertas — hentikan di hari pertama
- `terbaca: false` muncul di lebih dari 4 dari 10 soal
- Kecocokan di bawah 5 dari 10, atau AI berulang kali meyakinkan di atas pembacaan yang keliru

Di antara keduanya — 5 atau 6 cocok — artinya prompt yang perlu diperbaiki, bukan tesis yang gugur. Data goresan sudah tersimpan, jadi putaran perbaikan tidak perlu melibatkan anak lagi.

Rencana harian



HARI 1

Kanvas tinta + perekaman titik historis — selesai kalau menggambar terasa mulus & JSON berisi ribuan titik berwaktu



HARI 1

Tes 10 menit ke anak, coret-corek bebas — selesai kalau anak nyaman menulis dengan jari (kalau tidak, berhenti di sini)



HARI 2

Kanvas berlangkah, kotak jawaban, 10 soal, alur ekspor — selesai kalau satu sesi lengkap keluar sebagai satu berkas JSON



HARI 3

Skrip render goresan jadi PNG + hitung turunan waktu — selesai kalau Bapak bisa melihat kembali tulisan anak per langkah



HARI 4

Prompt diagnosis + structured output — selesai kalau skrip mengembalikan JSON diagnosis untuk 10 soal



HARI 5

Sesi uji sungguhan dengan anak — selesai kalau data terkumpul & Bapak sudah menilai sendiri lebih dulu



HARI 6–7

Wawancara, bandingkan, perbaiki prompt di atas data yang sama — selesai kalau angka kecocokan final ada

Tiga penyesuaian sebelum eksekusi

Lingkup dan gerbang di atas **tidak berubah** — ini murni memperkuat pelaksanaannya, dari riset yang baru selesai.

1. **Strukturkan wawancara pakai protokol 5-prompt NEA:** "Baca soal ini" → "Ceritakan apa yang diminta" → "Tunjukkan bagaimana kamu dapat jawabannya, ceritakan pikiranmu" → "Kerjakan sambil dijelaskan" → "Tulis jawabannya".
Menggantikan "coba jelaskan caramu" yang bebas.
2. **Jangan tambah kategori "Encoding" ke skema output.** Jawaban akhir diketik (bukan OCR) jadi kesalahan tulis-akhir nyaris tidak mungkin di jalur ini. Kalau muncul, catat manual saat wawancara, jangan ubah skema `kode`.

3. **Batas maksimal 3 putaran perbaikan prompt** untuk zona abu-abu (5–6 cocok) di atas data yang sama, sebelum memutuskan lulus/gagal final — supaya tidak diam-diam overfitting ke 10 soal satu anak ini.

05 Roadmap setelah spike

Melebar hanya kalau lapisan sebelumnya terbukti jalan — bukan bangun semua fitur dulu baru diuji.

FASE 0 sekarang

5-7 HARI

Spike — coretan ke diagnosis

10 soal hardcoded, satu anak, satu sesi uji. Membuktikan atau menggugurkan tesis inti sebelum satu baris kode "produk" ditulis.

FASE 1

SETELAH SPIKE LULUS

v1 harian, satu keluarga

- Lapisan pra-fondasi kelas 4 diputuskan lebih dulu (atau bersamaan) — PDF sumber tidak langsung cocok
- Graf topik berprasyarat menggantikan 10-soal-hardcoded
- Antrean pengulangan & buku kesalahan, menyusul graf topik
- Pipeline diagnosis tetap di Mac — jangan buru-buru pindahkan AI ke dalam aplikasi
- Tulis catatan DPIA ringkas di awal fase ini, sebelum data anak terkumpul rutin

FASE 2

SETELAH V1 STABIL

Foto kertas fisik

- SOP ambang ganda (auto-terima/auto-tolak/rute-ke-Bapak), bukan satu ambang tunggal
- Transkripsi verbatim selalu ditampilkan ke Bapak sebelum diagnosis jalan
- Kanvas bebas + OCR halaman-penuh dengan guard, bukan kotak jawaban kaku
- Pustaka pola kesalahan terkurasi (perluasan tabel sidik jari), bukan AI menebak bebas

Dashboard orang tua

Riset gagal menemukan pola tervalidasi untuk konteks non-institusi. Bapak sendiri yang jadi pengguna utama — laporan teks sederhana mungkin cukup lama sebelum ada alasan nyata membangun UI. Kalau dikerjakan, perlakukan sebagai riset+piloting kecil sendiri.

Tetap "Ditunda", tidak berubah: mode anak terkunci, kanvas geometri & daftar berbaris, AI di dalam aplikasi. Sudah diputuskan di rencana spike, riset ini tidak memberi alasan untuk mengubahnya.

06 Risiko & pertanyaan terbuka

RISIKO	KENAPA PENTING	KAPAN DIPUTUSKAN
Distribusi B/K/H pada anak SD kelas 4 belum tervalidasi	Studi NEA yang ditemukan semua pada anak SMP+; kalau "K" tidak dominan di usia ini, metrik utama perlu ditinjau	Setelah beberapa minggu data v1 riil
Overfitting prompt ke 10 soal satu anak	Bisa lolos gerbang teknis tanpa generalisasi	Sebelum mulai iterasi — pakai batas 3 putaran
PP 17/2025 belum ada preseden penegakan individu skala kecil	Kepatuhan sekarang preventif, bukan teruji hukum	Makin penting begitu Fase 2 simpan foto di cloud, bukan lokal
Ambang OCR dari literatur berasal dari ujian universitas	Angka spesifik kemungkinan tidak langsung berlaku ke anak SD	Piloting internal begitu Fase 2 dimulai
Dashboard orang tua mungkin tidak dibutuhkan sama sekali	Menghindari kerja yang tidak perlu	Ditinjau ulang setelah Fase 1 jalan beberapa bulan

07 Bentuk aplikasinya

Bukan aplikasi belajar yang bertambah fitur seiring waktu — alat diagnosis yang mulai sangat sempit dan baru melebar kalau tiap lapisan terbukti jalan.

UNTUK ANAK

Buka HP, lihat daftar soal — bukan level, bukan XP, bukan lencana.
Kanvas kosong berlangkah untuk coret-corek, jawaban akhir diketik terpisah. **Tidak ada skor yang ditampilkan.** Tidak ada AI yang mengobrol dengannya. Selesai ~10 soal atau 30–40 menit, 3x seminggu.

UNTUK BAPAK

Bukan rapor angka — peta topik mana yang punya **K aktif** dan trennya. "Salah konsep di pengurangan pecahan berpenyebut beda, sudah 3x dalam 2 minggu" — lengkap bukti dari coretan anak.
Bapak yang memutuskan mau diapakan.

Peran AI

Selalu di belakang layar, tidak pernah bicara ke anak. Membaca coretan + waktu pengerjaan, menerjemahkan jadi kode B/K/H dengan bukti — dan boleh mengaku tidak tahu kalau tulisannya memang tidak terbaca.

Bentuk teknis sekarang

Android tiga layar (daftar soal → kanvas menulis → ekspor), tanpa izin internet, tanpa akun, tanpa server. Diagnosis dijalankan terpisah lewat skrip di Mac. Pilihan sengaja, bukan keterbatasan sementara.

KAPAN	BENTUKNYA	YANG DIBUKTIKAN
Minggu ini	Spike — 10 soal, satu anak, satu sesi	Apakah AI beneran bisa baca cara berpikir anak dari coretannya
Setelah spike lulus	v1 harian — graf topik + antrean pengulangan	Dipakai beneran 3x/minggu, bukan cuma uji coba
Bulan-bulan berikutnya	+ Jalur foto kertas fisik, SOP ketat	Diagnosis tidak lagi terbatas ke layar HP
Kalau perlu	Dashboard/laporan lebih rapi	Baru kalau laporan teks ternyata kurang

Sumber: memori keputusan produk (14 Agustus 2026) · Rencana Spike – Coretan ke
Diagnosis.html · laporan riset dua-putaran (47 sumber, 38 klaim terverifikasi).

Dokumen kerja — perbarui setiap kali keputusan baru diambil, jangan biarkan basi.